

D——Transformer

管睿

23374318@buaa.edu.cn

摘要

针对"Attention is All You Need"论文复现任务，本文实现了 Transformer Encoder 的完整复现，并聚焦位置编码模块进行消融实验研究。通过设计位置依赖模式生成任务（输入全零序列，目标为位置索引的确定性映射），对比正弦位置编码、可学习绝对位置编码、无位置编码三种方案的性能。实验结果表明：正弦编码和可学习编码均在 1 个 epoch 内收敛至 100%准确率，而无位置编码方案准确率始终卡在 20%的随机基线水平，直观验证了位置编码是 Transformer 捕获序列顺序信息的必要组件

问题描述

Transformer 模型完全基于自注意力机制，摒弃了传统的循环/卷积结构，实现了高度并行化。然而，自注意力机制本身具有置换不变性（permutation equivariance），即输入序列的顺序打乱后，输出仅对应打乱，无法感知原始位置信息。

核心问题：位置编码是否为 Transformer 的必要组件？移除位置编码后，模型性能会退化到何种程度？不同位置编码形式对模型性能有何影响？

实验任务设计：输入 X：全为 0 的序列（彻底剥离内容干扰）；目标 Y： $Y[t] = t \% \text{vocab_size}$ （例如 [0,1,2,3,4...], 100% 由位置决定）；任务目标：模型需仅凭位置编码信息，预测每个时间步对应的位置索引类别。

该任务将位置编码的必要性转化为强控制变量实验，确保消融对比的尖锐性与结论的可靠性。

研究方法

1. Transformer Encoder 架构复现

本文复现了 Vaswani 等人（2017）提出的 Transformer Encoder 架构，核心模块包括：

（1）缩放点积注意力

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(2) 多头注意力机制

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

其中 $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$

(3) 位置编码模块（三种变体）

正弦位置编码（原始方法）、可学习绝对位置编码、无位置编码（消融对照）

(4) 前馈网络 + 残差连接 + 层归一化

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$


$$\text{LayerNorm}(x + \text{Sublayer}(x))$$

Table 1: 最佳训练结果配置项

配置项	参数值
序列长度	10
词汇表大小	5（随机基线=20%）
训练集/验证集	2000 / 500
批次大小	64
模型维度	128
Encoder 层数	2
注意力头数	4
前馈网络维度	256
Dropout	0.0（消融实验关闭）
优化器	Adam
最大训练轮数	30（早停 patience=6）

实验探究

1. 训练损失曲线分析



从损失曲线图可以观察到两种截然不同的收敛模式:

正弦/可学习编码：第 1 个 epoch 后 Loss 迅速降至 ≈ 0 ，收敛极快

无位置编码: Loss 停滞在 2.0 附近 ($\approx$ 随机猜测的理论 Cross-Entropy), 无法学习

2. 验证集准确率

Table 2: 验证集最佳准确率

位置编码类型	最佳准确率	收敛轮数
正弦编码	100%	1
可学习编码	100%	1
无编码	20%（随机基线）	-

3. 注意力可视化




Figure 2: 正弦编码注意力图

注意力分布：呈现从左到右的渐变模式，早期位置获得较高注意力（ ~ 0.18 ），逐渐衰减至后期位置（ ~ 0.06 ）
现象解释：正弦编码通过三角函数的周期性，为每个位置注入独特的几何特征，形成平滑的注意力梯度




Figure 3: 可学习编码注意力图

注意力分布：呈现稀疏的高亮斑点，部分位置注意力权重高达 0.8-1.0（黄色区域）
现象解释：模型通过数据驱动学习到了一些位置特异性模式，但分布不规则且噪声较大




Figure 4: 无编码注意力图

注意力分布：整个热力图呈现均匀的青绿色，所有位置的注意力权重约为 0.10（即 1/10 的均匀分布）

现象解释：自注意力机制无法区分不同位置，退化为均匀注意力（uniform attention）
理论验证：直接证明了自注意力的置换不变性缺陷

结论

- 1.位置编码是 Transformer 的必要组件：实验结果显示，移除位置编码后，模型准确率骤降至随机基线（20%），Loss 无法进一步降低，验证了自注意力机制的置换不变性缺陷。位置编码为 Transformer 提供了唯一的位置信息来源。
- 2.正弦编码与可学习编码在位置任务上等价：两种编码方案均实现 100%准确率，收敛速度均极快（1 个 epoch）。正弦编码凭借三角函数的几何性质提供平滑的位置梯度；可学习编码通过数据驱动获得离散的高注意力模式
- 3.实验设计的科学价值：通过设计"输入全零、目标由位置决定"的极端任务，本文实现了最大化的控制变量对比，使得位置编码的作用被放大到极致（100% vs 20%），为《Attention is All You Need》论文第 3.5 节的理论论述提供了直观、有力的实验证据
- 4.实践指导意义：对于位置敏感任务（如序列标注、机器翻译），必须引入位置编码；对于固定长度任务，可学习编码与正弦编码效果相当，可根据实现便利性选择；对于变长序列或需外推的任务，正弦编码的数学先验更具优势（本文虽未测试外推，但可学习编码的稀疏注意力图暗示其泛化性可能较弱）。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in neural information processing systems. 2017, 30: 5998-6008
- [2] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [3] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020